Практическая применимость проекта

Incident Copilot — RAG-система для поддержки диагностики программных инцидентов

Проблема и целевая аудитория

В работе SRE- и DevOps-инженеров, специалистов технической поддержки и разработчиков причины сбоев приходится искать в разрозненной документации, runbooks, описаниях прошлых инцидентов и обсуждениях. Ручной поиск увеличивает время диагностики и зависит от опыта конкретного сотрудника. Особенно болезненны повторяющиеся инциденты, ночные дежурства и передача знаний между командами.

Предлагаемое решение и сценарий использования

Incident Copilot получает вопрос на естественном языке (например, «Почему контейнер постоянно перезапускается?»), находит релевантные фрагменты технической базы знаний и формирует объяснение с указанием источников, возможных причин и шагов проверки. Пользователь должен видеть, на каких документах основан ответ, и иметь возможность быстро перейти к первоисточнику. На первом этапе система предназначена для информационной поддержки, а не для автоматического исполнения команд в инфраструктуре. В дальнейшем планируется исследовать, помогает ли совместный учёт текста, скриншотов пользователя и иллюстраций из документации точнее отвечать на вопросы, в которых важны визуальные детали.

Реализуемость и ограничения

Создание исследовательского прототипа реалистично: доступны открытая документация Kubernetes, инженерные runbooks, отдельные отчёты об инцидентах и готовые модели для поиска и генерации. В то же время открытый корпус не отражает внутреннюю инфраструктуру конкретного заказчика; без подключения его актуальных документов система не сможет отвечать на часть практических вопросов. Для промышленного применения потребуются регулярное обновление индекса, учёт версий документации, разграничение доступа и интеграция с внутренней базой знаний.

Риски и способы их снижения

Критичны три группы рисков: устаревшая информация, недостоверные или опасные рекомендации модели и утечка конфиденциальных сведений из логов и внутренних документов. Предусматриваются ответы с проверяемыми ссылками, явное обозначение неопределённости и отказ от ответа при недостатке данных, контроль версий и прав доступа, а также исключение чувствительных данных из публичных экспериментов. Любые действия, способные изменить состояние системы, остаются за инженером.

Оценка качества и ценности для заказчика

На этапе исследования качество поиска можно измерять с помощью Recall@K, MRR и nDCG@K на размеченных запросах. Качество итогового ответа — через корректность фактов, соответствие найденным источникам, полноту диагностических рекомендаций и частоту уверенных ошибочных ответов. Практическую пользу следует проверять сравнительным тестированием с ручным поиском: время до обнаружения вероятной причины, доля успешно решённых типовых кейсов и субъективная полезность ответов для инженеров. Целевой эффект — ускорение первичной диагностики без снижения безопасности и надёжности решений.